中国科学院大学
University of Chinese Academy of Sciences

硕士学位论文

面向大语言模型强化学习后训练的难度感知自适应采样策略研究

作者姓名：闫嘉序

指导教师：李伟 研究员 中国科学院计算技术研究所

学位类别：工学硕士

学科专业：计算机科学与技术

培养单位：中国科学院计算技术研究所

2026 年 6 月

Difficulty-Aware Adaptive Sampling Strategies for Reinforcement Learning Post-Training of Large Language Models

A thesis submitted to

University of Chinese Academy of Sciences

in partial fulfillment of the requirement

for the degree of

Master of Engineering

in Computer Science and Technology

By

Jiaxu Yan

Supervisor: Prof. Wei Li

Institute of Computing Technology, Chinese Academy of Sciences

June, 2026

中国科学院大学
学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明或致谢。

作者签名：

日　　期：

中国科学院大学
学位论文授权使用声明

本人完全了解并同意遵守中国科学院有关保存和使用学位论文的规定，即中国科学院有权保留送交学位论文的副本，允许该论文被查阅，可以按照学术研究公开原则和保护知识产权的原则公布该论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名：　　导师签名：

日　　期：　　日　　期：

摘要

大语言模型在数学推理等可验证任务上的后训练，越来越依赖基于组采样的强化学习方法。然而，固定小组采样会导致一个经常被忽视的统计问题：当同一 prompt 采样得到的回答全对或全错时，组内奖励方差退化，进而造成零梯度更新。本文将这一现象概括为 *signal collapse*，并指出其根源并不完全在于题目是否可学，而在于训练预算与 prompt 难度之间存在显著错配。换言之，许多“学不到”的表面现象，实际上是固定预算在异质难度分布上无法稳定暴露正负对比信号的结果。

围绕这一问题，本文构建了一个“统计分析—采样机制—系统友好性”相统一的研究框架。基于 Qwen2.5-Math-1.5B base 在 OpenR1-Math-220k 上的 prompt 级重复采样统计与训练 checkpoint 切片，本文系统分析了固定预算、自适应固定块预算和几何块预算的差异，并刻画训练数据内部显著存在的难度长尾与分层结构。研究表明：即使组大小提升到 32，训练前后仍分别有 35.36% 与 26.41% 的 prompt 发生 signal collapse；在此背景下，自适应采样较固定预算具有更低的信号缺失率，而几何块自适应策略在保持统计效果的同时，更适合后续与 KV Cache 复用等系统优化结合。进一步地，本文比较了“有对有错就停”与“只要有对就停”两类退出规则，发现正样本优先规则在现有预算下具有更高的预算效率，并且这种优势可以用停止时间分布与单位预算信号收益的差异进行解释。最后，本文进一步讨论几何块批次组织与前缀复用、在线流水线调度以及温度缩放重要性校正之间的衔接方式，从而把采样问题扩展为统计效率与系统效率的联合设计问题。

本文的工作说明，在 reasoning 强化学习后训练中，采样预算本身就是训练信号设计的一部分。与其仅从损失函数角度理解训练稳定性，不如将 prompt 级预算分配、退出规则和系统批次组织作为统一问题加以设计。本文最终主张：采样不应被视为训练外部的附属开销，而应被视为决定训练信号是否能够被有效观测的内部机制。

关键词：大语言模型，强化学习后训练，自适应采样，信号坍塌，数学推理

Abstract

Reinforcement learning post-training for large language models has recently become a major approach for improving mathematical reasoning. A practical difficulty of group-based optimization, however, is that fixed small-group sampling often yields all-correct or all-incorrect response sets for the same prompt, causing the within-group reward variance to vanish and the gradient signal to collapse. This thesis studies the problem from the perspective of prompt-level sampling allocation and argues that many zero-signal cases are induced by budget mismatch rather than the intrinsic unlearnability of prompts.

To address this issue, the thesis develops a unified perspective that connects statistical analysis, sampling design, and systems-friendly execution. Using prompt-level repeated sampling statistics and checkpoint slices from the Qwen2.5-Math-1.5B base model trained on OpenR1-Math-220k, it characterizes the long-tail structure of prompt difficulty, analyzes the evolution of signal collapse during training, and compares fixed-budget, fixed-block adaptive, and geometric-block adaptive sampling strategies. The results show that the sampled training data exhibits a pronounced long-tail difficulty structure; signal collapse remains substantial even with group size 32; adaptive sampling consistently outperforms comparable fixed budgets; and geometric-block scheduling achieves nearly the same statistical effectiveness as fixed-block scheduling while offering a more system-friendly batch structure. Moreover, under the current budget, a positive-first stopping rule is more cost-effective than a balanced stopping rule, and this difference can be interpreted through the stopping-time behavior of prompts with heterogeneous success probabilities. Finally, the thesis discusses how geometric-block scheduling can better interface with prefix reuse, KV-cache-aware execution, and temperature-based importance correction in future system implementations.

These findings suggest that sampling allocation should be viewed as an integral part of signal design in reasoning-oriented reinforcement learning, together with the stopping rule and systems-level batch organization.

Keywords: large language models, reinforcement learning post-training, adaptive sampling, signal collapse, mathematical reasoning

目 录

第 1 章 引言 ····· 1
1.1 研究背景 ····· 1
1.2 强化学习后训练中的组采样问题 ····· 1
1.3 Signal Collapse 的经验动机 ····· 2
1.4 研究目标与本文贡献 ····· 2
1.5 研究意义 ····· 5
第 2 章 相关工作 ····· 7
2.1 大语言模型与后训练范式 ····· 7
2.2 数学推理与可验证奖励训练 ····· 7
2.3 组相对强化学习与信号缺失问题 ····· 7
2.4 数据过滤、预算分配与自适应采样 ····· 8
2.5 推理系统优化与 KV Cache 视角 ····· 8
2.6 本章小结 ····· 10
第 3 章 难度感知的自适应采样方法 ····· 11
3.1 问题定义 ····· 11
3.2 难度异质性与预算效率分析 ····· 11
3.3 几何块自适应采样框架 ····· 12
3.4 两类退出规则 ····· 14
3.4.1 平衡退出规则 ····· 14
3.4.2 正样本优先退出规则 ····· 14
3.5 退出规则的停止时间分析 ····· 15
3.5.1 平衡退出规则的停止时间 ····· 15
3.5.2 正样本优先规则的停止时间 ····· 16
3.5.3 单位预算的边际信号收益 ····· 16
3.6 训练时采样流程的算法化描述 ····· 17
3.7 复杂度与系统实现讨论 ····· 18
3.8 分布一致性扩展讨论 ····· 18
3.9 本章小结 ····· 19

第 4 章 实验设计与结果分析 ····· 21
4.1 实验设置 ····· 21
4.2 Prompt 难度分布统计 ····· 21
4.3 信号坍塌的训练前后对比 ····· 23
4.4 自适应采样策略比较 ····· 25
4.5 训练动态分析 ····· 27
4.6 本章小结 ····· 29
第 5 章 讨论 ····· 31
5.1 为何正样本优先规则更具预算效率 ····· 31
5.2 几何块策略的联合收益 ····· 32
5.3 从采样策略到隐式课程学习 ····· 32
5.4 与既有研究结论的关系 ····· 33
5.5 局限性 ····· 33
5.6 效度威胁分析 ····· 34
5.7 实践启示与设计建议 ····· 35
第 6 章 结论与展望 ····· 37
6.1 主要结论 ····· 37
6.2 本文贡献回收 ····· 38
6.3 未来展望 ····· 38
附录 A 附录：补充公式与统计说明 ····· 41
A.1 固定组采样下的 signal collapse 概率 ····· 41
A.2 单位预算信息效率近似 ····· 41
参考文献 ····· 43
致谢 ····· 47
作者简历及攻读学位期间发表的学术论文与研究成果 ····· 49

第 1 章　引言

1.1　研究背景

大语言模型在自然语言理解、程序生成和多步推理等任务上持续取得突破，其核心技术路线已经从“预训练规模扩张”逐渐转向“预训练能力如何在后训练阶段被稳定激发”[1–5]。尤其是在数学推理、代码推理和科学问答等可验证任务中，模型是否能够稳定输出高质量长链路解答，越来越依赖后训练阶段的强化学习过程 [6–10]。

与传统监督微调不同，强化学习后训练不再直接模仿参考答案，而是通过奖励信号调整策略模型在候选解空间中的搜索分布。当任务具备明确答案校验器时，强化学习能够把“是否答对”这一离散反馈直接传递给策略优化过程，从而为数学推理训练提供较清晰的学习信号 [11–15]。这也是近年来 reasoning 模型大量采用 verifiable reward 的主要原因。

1.2　强化学习后训练中的组采样问题

尽管奖励定义相对清晰，但 reasoning 训练依然面临显著的高方差问题。一个常见做法是对同一 prompt 采样多个回答，再利用组内平均值与标准差构造相对优势函数，以此降低尺度差异并稳定训练 [10, 16, 17]。然而，这类方法也引入了一个基础但严重的问题：如果同一组采样结果恰好全对或全错，组内奖励方差就会趋于零，造成有效梯度消失。

形式化地，若同一 prompt 的单次答对概率为 p_x，组大小为 n，则该 prompt 在一次组采样中发生全对或全错的概率为 $p_x^n + (1 - p_x)^n$。当 n 较小而训练数据的难度分布又高度异质时，这一概率会在训练全过程中反复出现。对于困难题，它表现为大量“全错组”；对于简单题，它又会在训练中后期演化为“全对组”。因此，零信号并不是训练早期的暂时噪声，而是固定小组采样与真实难度分布不匹配的结构性后果。

1.3 Signal Collapse 的经验动机

为了更具体地展示这一问题，本文首先统计了 Qwen2.5-Math-1.5B base 在 OpenR1-Math-220k 抽样切片上的 prompt 级正确率分布。结果显示，样本平均正确率为 0.2623，中位数仅为 0.1055，但上四分位已达到 0.4609，呈现明显的低端堆积与高端长尾并存结构。这意味着训练集中同时存在大量“几乎答不对”的样本和一批“经常能答对”的样本，难度差异极大。

更进一步地，本文使用每题 256 次重复采样得到的经验正确率，估计固定组大小下的总体 signal collapse 概率。结果表明：在训练起点，组大小为 $4, 8, 16, 32$ 时的总体坍塌率分别达到 65.35%、52.91%、43.08% 和 35.36%；到了训练第 600 步，这一数值虽下降至 55.95%、41.98%、32.75% 和 26.41%，但仍处于不可忽视的高位。换言之，即使显著增加组大小，固定采样也难以彻底解决训练信号缺失问题。

这一定量结果与 pass@k 类研究形成呼应。多次采样往往能显著提升模型找到正确答案的概率，说明单次或小组采样所呈现出来的“无信号”并不等同于“模型没有潜在能力”[18–20]。因此，本文将关注点从“如何修改损失函数”转向“如何更合理地为 prompt 分配采样预算”。

1.4 研究目标与本文贡献

基于上述观察，本文试图回答以下问题：第一，固定小组采样为何会在 reasoning 训练中系统性地产生 signal collapse；第二，prompt 级难度异质性如何影响采样预算的边际收益；第三，是否存在一种更适合系统实现的自适应预算组织方式，在不明显牺牲统计效果的前提下降低无效开销。

围绕这些问题，本文的主要工作可概括为以下三点：

1. 基于 OpenR1-Math-220k 抽样数据与训练 checkpoint 切片，系统量化了 reasoning 强化学习训练中的 prompt 难度分布与 signal collapse 现象，证明零信号并非偶发异常，而是固定小组采样下的常态风险。

2. 从预算效率角度分析了不同退出规则的差异，指出正样本优先规则在当前数据下较平衡规则更具成本效益，支持“把简单题节省下的预算转移给更难题目”的难度感知思想。

3. 比较固定块与几何块两种自适应采样组织方式，说明几何块方法在统计

效果接近的前提下具有更规整的批次结构，为后续 KV Cache 复用与系统并行优化提供了更自然的接口。

图 1.1 给出了本文的整体论证框架。整篇论文围绕一个核心判断展开：reasoning 强化学习中的训练停滞并不只是优化器问题，更是 signal collapse 在异质难度分布上的系统性表现。为验证这一判断，本文首先用 prompt 级统计量刻画问题，再提出难度感知自适应采样框架，最后通过分布、坍塌率、预算效率和训练动态四类证据形成闭环论证。

从章节组织上看，图中的上半部分对应本文前两章的任务：第 2 章负责说明这一问题在既有文献中的位置与研究缺口；第 3 章则把“预算如何分配、何时停止、如何组织采样”转化为可执行的方法框架。换言之，总览图首先给出的是全文论证蓝图，而后续相关工作矩阵与方法流程图分别承担“文献定位”和“方法落地”两种不同功能。

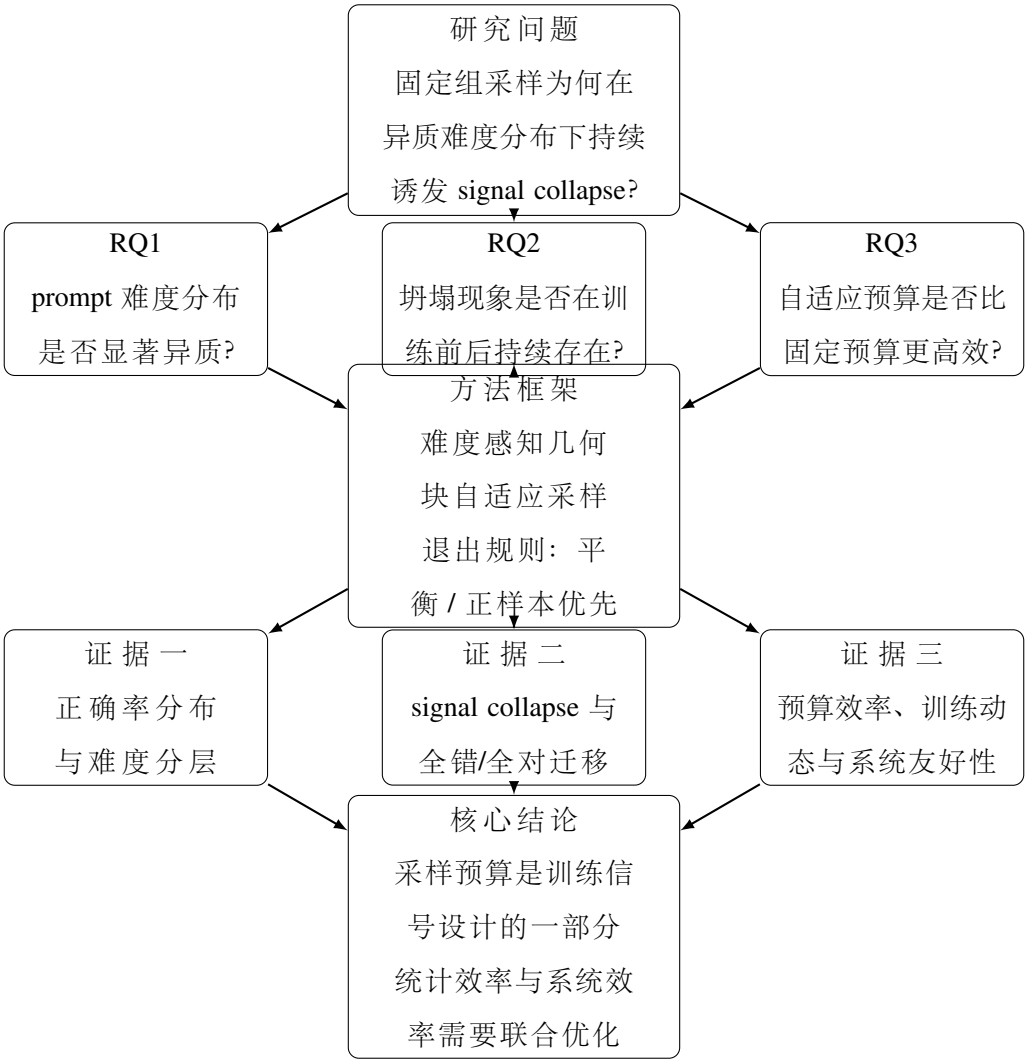

图 1.1 本文整体论证框架总览

Figure 1.1 Overall argument structure of this thesis.

1.5　研究意义

本文的意义主要体现在三个层面。

第一，在理论层面，本文将 reasoning 强化学习训练中的“零梯度”现象明确表述为 prompt 级 signal collapse，并给出与组大小、题目难度分布直接相关的概率表达式。这样的表述把一个过去常被视为“训练不稳定”或“优化器噪声”的经验问题，转化为可以被分析、度量与比较的统计对象。对后续研究而言，这意味着不同采样策略、退出规则与温度机制都可以在统一的 prompt 级风险框架下进行讨论。

第二，在方法层面，本文强调采样预算本身也是训练信号设计的一部分。以往很多工作将采样过程视为固定前置步骤，把主要精力放在奖励模型、优势函数或优化目标的改进上；而本文表明，在数据难度异质性显著存在时，预算如何按 prompt 分配、何时提前停止以及如何组织增量采样，都会直接决定训练中可被观测到的有效对比信号总量。因此，采样并不是训练外部的“数据准备”，而是训练内部的“信号构造”。

第三，在系统层面，本文指出统计效率与系统效率并非相互割裂。几何块采样不仅影响缺失率与平均成本，也决定了同前缀多回答生成能否以更规整的方式调度，从而影响 KV Cache 复用和批次吞吐。对于大规模 reasoning 训练而言，这一点尤其重要：当单轮训练需要处理海量 prompt 与长链路回答时，采样策略是否利于系统执行，往往会转化为真实 wall-clock 成本差异。

换言之，本文的目标并不只是提出一个局部采样技巧，而是尝试给出一个统一视角：在可验证奖励的 reasoning 场景中，训练信号质量来源于“概率分布、预算分配与系统调度”三者的共同作用。只有将三者作为一个整体来理解，后训练过程中的许多经验现象才能被更系统地解释。

本文后续结构安排如下：第 2 章综述相关工作；第 3 章给出难度感知自适应采样方法；第 4 章介绍实验设计与结果；第 5 章进行讨论；第 6 章总结全文并展望后续研究。

第 2 章　相关工作

2.1　大语言模型与后训练范式

大语言模型的发展通常经历预训练、监督微调与后训练三个阶段。预训练阶段依托 Transformer 架构与海量语料学习通用表征能力，典型代表包括 GPT-3、LLaMA 与 Qwen 系列模型 [1–5]。随着模型规模与数据规模增长，后训练成为决定模型是否能够稳定遵循指令、保持安全约束并在复杂任务上获得高质量推理行为的关键环节 [6–9, 21, 22]。

在人类反馈强化学习之外，近年来也出现了直接偏好优化、AI 反馈强化学习、安全后训练以及对奖励模型质量进行专门评测的工作 [7, 8, 21, 23]。这些工作共同说明：后训练并不是一个单一优化器问题，而是目标函数、奖励来源、采样机制和推理系统共同作用的结果。

2.2　数学推理与可验证奖励训练

数学推理任务之所以成为研究强化学习后训练的重要试验场，在于其奖励信号相对清晰，模型输出通常可以通过最终答案校验、步骤级校验或外部验证器获得近似二值的反馈 [11, 13–15, 24]。GSM8K、MATH、Minerva Math、Olympiad-Bench、Omni-MATH 以及 PutnamBench 等基准构成了从基础文字题到高难竞赛题的多层次评测体系 [11, 12, 14, 25–27]。

此外，链式思维、自一致性采样和步骤级验证等方法进一步推动了数学推理研究的发展 [13, 19, 28]。这些工作强调，多样化采样对于发掘模型潜在能力具有重要意义；但与此同时，采样预算本身也会显著影响最终训练信号质量。

2.3　组相对强化学习与信号缺失问题

在可验证奖励场景中，组相对归一化策略优化因其实现简单、训练稳定而受到广泛关注。作为这一路线的更一般优化背景，PPO 等策略梯度方法已经系统讨论了如何在受限更新幅度下稳定提升策略 [29]；DeepSeek-R1 及其后续工作则表明，按 prompt 采样多个回答并利用组内统计量构造优势函数，能够在推理任务上显著提升模型表现 [10, 16]。然而，这类方法隐含依赖于一个前提：同一

prompt 下采样得到的回答必须具有足够的奖励差异，否则组内标准差退化后将难以形成有效梯度。

围绕这一问题，近期研究从不同角度给出了解释。一类工作指出，强化学习更擅长激发模型已经具备但尚未稳定外显的能力，而非凭空创造新的能力上限 [20, 30]。另一类工作则通过 pass@k 评估、重采样分析与长链路推理研究说明，多次采样可以显著暴露单次采样难以观察到的潜在正确解 [14, 18, 19]。这些结论共同暗示：当固定小组采样无法覆盖 prompt 内部的正负样本差异时，所谓的“无信号”很可能只是小样本统计假象。

2.4 数据过滤、预算分配与自适应采样

针对组内信号缺失问题，已有研究大致可以分为三类。第一类方法采用被动过滤，即先按照固定预算生成回答，再丢弃全对或全错的 prompt。这类思路实现门槛较低，但已经支付的推理成本无法回收，且难题上稀缺的训练信号会被一并丢弃。第二类方法通过直接放大采样规模来缓解信号退化，其优点是简单有效，但成本通常随组大小线性上升，难以在大规模训练中长期维持 [10, 31]。

第三类方法尝试通过自适应预算分配改善采样效率。Reinforce-Ada 提出了在线多轮采样与早停机制，强调在非线性强化学习目标下按需收集样本的重要性 [17]。近年的 LLM reasoning 后训练工作则进一步从 selective rollouts、难度对齐和在线数据选择等角度讨论了预算应如何向更有价值的 prompt 倾斜 [32–35]。从更广义的强化学习视角看，主动重要性采样、条件重要性采样和双稳健策略梯度等方法都在讨论如何将有限预算优先投向更有价值的样本区域 [36–39]。本文继承这一基本思路，但关注点更进一步：在 reasoning 训练中，不同难度 prompt 的“单位预算信息回报”高度不均匀，退出规则与批次组织方式都应显式考虑这种难度异质性。

2.5 推理系统优化与 KV Cache 视角

除了统计层面的预算分配，现代大语言模型训练与推理系统也越来越强调前缀复用、调度效率和 KV Cache 管理 [40–42]。对于同一 prompt 的多回答采样，若能够以更规整的批次结构组织生成过程，就有机会减少前缀重复编码，提升吞吐并降低延迟。因此，采样策略的优劣并不只体现在统计信号密度上，也体现在

是否与底层推理系统的并行结构相协调。

基于这一观察，本文并不将自适应采样仅仅视为一个数学上的停止规则问题，而是将其视为“统计效率—系统效率”联合优化问题：前者关注能否更早暴露正负样本差异，后者关注能否以更少的系统开销完成同样的重采样任务。

为更清晰地定位本文与已有工作的关系，表 2.1 从奖励来源、采样组织、研究重点以及是否显式讨论系统执行四个维度，对代表性工作进行了横向比较。可以看到，已有工作要么强调 reward 设计与训练稳定性，要么强调多样本推理与测试时扩展，而较少将 prompt 难度异质性、退出规则与批次组织方式放在同一框架下讨论。本文的差异正体现在这里：我们不把采样仅视作固定前置步骤，而把它视作训练信号形成机制的一部分。

若将这一比较放回引言中的总览框架，可以把表 2.1 理解为“问题定位层”的展开：它回答的不是本文方法具体如何运行，而是“为什么现有文献还不足以直接回答本文提出的研究问题”。因此，本章的任务是把研究空白定义清楚，而下一章的方法流程图则进一步回答“在这一空白上，本文打算如何构造解决方案”。

表 2.1 本文与代表性相关工作的比较

Table 2.1 Comparison between this thesis and representative related work.

工作	奖励来源	采样组织	主要关注点	是否涉及系统执行
PPO / RLHF[6, 29]	人类偏好或奖励模型	固定批次	稳定优化与偏好对齐	否
DeepSeekMath / GRPO[10]	可验证结果奖励	固定组采样	组相对优势与推理强化学习	否
Self-Consistency[19]	无显式训练奖励	测试时多样本采样	多样本聚合提升推理准确率	否
Reinforce-Ada[17]	可验证奖励与组内信号	在线增量采样	非线性 RL 目标下的自适应预算分配	部分
KV Cache 系统优化 [40–42]	不直接依赖奖励	服务期调度	前缀复用、吞吐与缓存管理	是
本文	可验证二值奖励	难度感知几何块自适应采样	signal collapse、预算效率与系统友好组织	是

2.6 本章小结

本章从五条主线回顾了与本文最相关的研究：大语言模型后训练、数学推理与可验证奖励、组相对强化学习、预算分配与自适应采样，以及面向推理系统的 KV Cache 优化。综述结果表明，现有工作已经分别从 reward、优化器、多样本推理和系统执行等角度讨论了 reasoning 训练问题，但对“固定小组采样如何在异质难度分布上持续诱发 signal collapse，以及采样策略如何同时影响统计效率与系统效率”的分析仍然不足。下一章将在这一研究缺口上给出本文的形式化方法与设计框架。

第 3 章　难度感知的自适应采样方法

3.1　问题定义

设 prompt 分布为 $x \sim d_0$，策略模型为 $\pi_\theta(y \mid x)$，回答 y 经验证器判定后得到奖励 $r(x, y) \in \{0, 1\}$。强化学习后训练的目标可以写为

$$J(\theta) = \mathbb{E}_{x \sim d_0,\, y \sim \pi_\theta(\cdot \mid x)}[r(x, y)]. \tag{3.1}$$

对给定 prompt x，记单次采样答对的真实概率为 p_x。若采用固定组大小 n 的组相对更新，组内全对或全错都会导致奖励方差趋于零。相应地，prompt 级“信号坍塌”概率可以表示为

$$P_{\text{collapse}}(x; n) = p_x^n + (1 - p_x)^n. \tag{3.2}$$

对全体训练分布求期望后，可得固定组大小下的总体坍塌率

$$P_{\text{collapse}}(n) = \mathbb{E}_{x \sim d_0}[p_x^n + (1 - p_x)^n]. \tag{3.3}$$

该式揭示了一个关键事实：即使所有 prompt 都满足 $0 < p_x < 1$，只要 n 足够小，整体训练中仍会频繁出现统计意义上的“零信号”事件。因此，本文关心的问题不是简单地判断某题是否可学，而是讨论在预算受限条件下，如何为不同难度 prompt 分配更合适的采样次数。

3.2　难度异质性与预算效率分析

若目标是尽快观察到正负样本差异，则 prompt 的学习价值不仅取决于正确率本身，也取决于少数类样本的获取成本。对二值奖励而言，单样本方差信息可由 $p_x(1 - p_x)$ 表征。若进一步考虑在训练后期仍需保留错误样本，则其单位成本信息效率可近似写为

$$\eta(p_x) \propto p_x(1 - p_x)^2. \tag{3.4}$$

当 $p_x = 0.9$ 时，$\eta(p_x) = 0.009$；当 $p_x = 0.3$ 时，$\eta(p_x) = 0.147$。这意味着在相同预算下，中等偏难样本能够产生远高于简单样本的有效对比信息。若训练过

程继续对高通过率 prompt 强行追求“平衡”的正负样本数量，就会在后期为少量 hard negative 付出不成比例的重采样开销。

基于这一分析，本文主张将退出规则与批次预算设计成难度敏感的形式：对高成功率 prompt，允许更早停止并将预算腾挪给中等难度样本；对低成功率或中等成功率 prompt，则保留额外采样空间，以便更稳定地暴露正负差异。

为了进一步把“预算效率”写成可比较的量，下面考虑固定组大小下首次观察到有效差异的等待时间。若采用平衡型更新，则一个 prompt 在单轮中形成有效信号，等价于组内至少同时出现一个正确样本和一个错误样本。对独立采样近似而言，其单轮成功概率为

$$q_{\mathrm{bal}}(p_x; n) = 1 - p_x^n - (1 - p_x)^n. \tag{3.5}$$

于是，首次观察到有效信号所需的期望轮数可写为

$$\mathbb{E}[T_{\mathrm{bal}}] = \frac{1}{q_{\mathrm{bal}}(p_x; n)}. \tag{3.6}$$

该式说明，固定预算的真实低效并不只表现为“某一轮恰好坍塌”，更表现为大量 prompt 需要跨越多个训练轮次，才能偶然获得一次非零梯度机会。当 p_x 很小或很大时，q_{bal} 都会迅速下降，从而导致等待时间急剧增长。

进一步地，当关注的是训练后期的简单题，即 $p_x \to 1$ 时，可令 $\delta_x = 1 - p_x$，则

$$q_{\mathrm{bal}}(p_x; n) = 1 - (1 - \delta_x)^n - \delta_x^n \approx n\delta_x, \tag{3.7}$$

其中近似利用了 $\delta_x \ll 1$ 时的一阶展开。这意味着，对高通过率 prompt 而言，平衡规则的额外成本本质上由“找到一个错误答案”的等待时间主导，其期望追加开销近似与 $1/(n\delta_x)$ 同阶增长。换言之，当错误样本已经成为少数类时，继续要求平衡退出，会把越来越多预算消耗在寻找稀有 hard negative 上。

3.3 几何块自适应采样框架

为兼顾统计效率与系统效率，本文采用几何块自适应采样框架。对每个 prompt，不再一次性采样固定 n 条回答，而是按块逐轮追加采样。设块序列为

$$\mathcal{B} = \{2, 2, 4, 8, 16\}, \tag{3.8}$$

其总预算上限为 32。第 t 轮结束后，根据当前累计样本集合 $S_x^{(t)}$ 判断是否继续采样。

该设计具有三点动机。第一，小块起步可以在训练早期快速确认极易题和极难题是否值得继续采样。第二，几何扩张使困难 prompt 获得越来越大的后续预算，而简单 prompt 往往在前两轮即可退出。第三，更规整的块结构更适合与前缀复用和 KV Cache 管理结合，从而减少重复编码开销。

图 3.1 给出了本文方法的概念流程图。与固定组采样“一次性生成、一次性更新”的流程不同，本文方法在 prompt 级维护一个动态活跃集合：每一轮只对仍未满足退出条件的样本继续追加预算，其余样本则提前退出。最终，活跃集合与样本池状态共同决定哪些 prompt 会进入后续更新构造阶段。

若与引言中的总览图对照，图 3.1 对应的正是其中“方法框架”那一层：总览图说明本文要回答哪些研究问题，而这里的流程图则把这些问题具体落实为活跃集合、几何块预算、退出规则和更新构造四个可操作部件。也正因为如此，相关工作矩阵、总览图和方法流程图在本文中并不是重复表达，而是分别承担“研究定位—全局框架—局部实现”三种不同粒度的叙事功能。

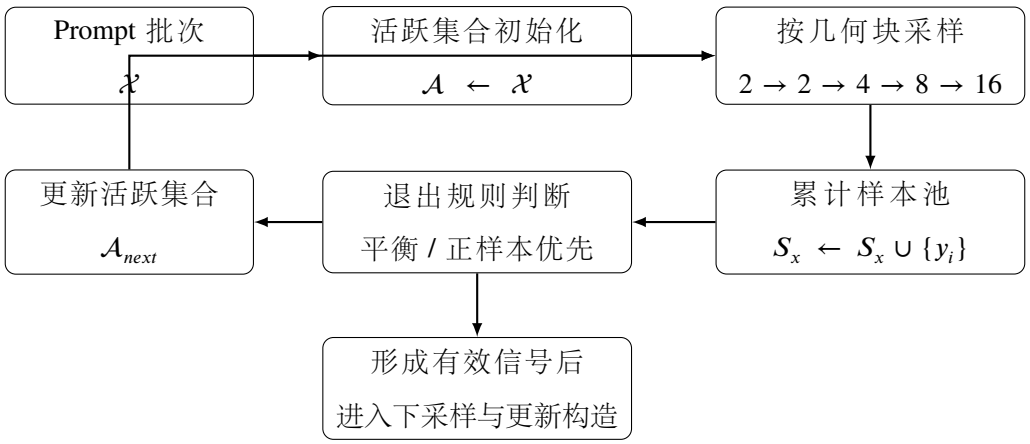

图 3.1 难度感知自适应采样的概念流程图

Figure 3.1 Conceptual pipeline of difficulty-aware adaptive sampling.

从实现角度看，这一框架还具有一个重要优点：它不要求训练系统在一开始为每个 prompt 分配固定长度的回答队列，而是允许在轮次边界上以 prompt 为粒度动态调整活跃集合。于是，真正消耗大块预算的只会是那些在前几轮尚未形成可分辨信号的样本，而非全体样本。这种“逐轮淘汰活跃 prompt”的机制，使得自适应采样天然适合与在线训练流水线结合。

3.4 两类退出规则

结合现有实验数据，本文重点分析两类退出规则。

3.4.1 平衡退出规则

平衡退出规则要求当前样本集合中同时出现正确与错误回答，才能认定该 prompt 已经形成有效训练信号。其优势在于显式保留正负样本对照，缺点是在训练后期可能为简单题反复追加采样，只为“寻找一个错误答案”。

若总预算上限为 m，则平衡退出在预算耗尽前成功停止的概率可写为

$$P_{\text{stop}}^{\text{bal}}(p_x; m) = 1 - p_x^m - (1 - p_x)^m. \tag{3.9}$$

相应地，失败事件恰好就是 signal collapse。该表达式说明，平衡规则虽然最符合组相对更新的原始直觉，但它对简单题和极难题都不友好：前者缺少负样本，后者缺少正样本，二者都会把 prompt 长时间保留在活跃集合中。

3.4.2 正样本优先退出规则

正样本优先退出规则在观测到至少一个正确回答后即可停止采样，仅将“预算耗尽仍全错”的 prompt 视作缺失样本。该规则更加节省预算，尤其适用于模型已经具备一定基础能力时的中后期训练阶段。它的核心思想不是否认负样本的重要性，而是承认在有限预算下，简单题上的额外找错成本未必比把预算转移给难题更划算。

在同样的总预算上限 m 下，正样本优先规则的成功停止概率为

$$P_{\text{stop}}^{\text{pos}}(p_x; m) = 1 - (1 - p_x)^m. \tag{3.10}$$

当 $p_x > 0$ 时，总有 $P_{\text{stop}}^{\text{pos}}(p_x; m) \geq P_{\text{stop}}^{\text{bal}}(p_x; m)$，且不等式在 $p_x \in (0, 1)$ 上通常严格成立。原因在于，正样本优先只要求观察到“至少一个正样本”，而不再额外要求同时命中稀有负样本。因此，对训练中后期的高通过率 prompt 而言，该规则能以更高概率在较小预算内提前退出，并把节省下来的预算转移给那些仍处于“正样本稀缺”区间的题目。

若进一步用几何分布近似正样本首次出现的等待时间，则其期望采样步数满足

$$\mathbb{E}[\tau_{\text{pos}}] \approx \frac{1}{p_x}. \tag{3.11}$$

这一定量关系揭示了正样本优先规则的另一个优势：它天然更关注“正样本何时首次暴露”，因此更适合服务于能力显化型训练阶段；而平衡规则则额外叠加了对稀有反例的搜索开销。本文实验中观察到的成本差异，本质上正对应了这两种等待时间结构的不同。

3.5　退出规则的停止时间分析

为了更精确地解释两类退出规则为何会产生不同的预算效率，本文进一步将 prompt 级采样过程写成一个离散停止时间问题。设块序列为 $\mathcal{B} = \{B_1, B_2, \dots, B_T\}$，累计预算记为

$$M_t = \sum_{i=1}^{t} B_i, \qquad M_0 = 0. \tag{3.12}$$

对任意 prompt x，若第 t 轮结束后仍未满足退出条件，则称其在第 t 轮后仍处于“存活”状态。记该存活概率为 $q_t(x)$，则期望采样成本可以统一写为

$$\mathbb{E}[C \mid x] = \sum_{t=1}^{T} B_t\, q_{t-1}(x), \qquad q_0(x) = 1. \tag{3.13}$$

这一定义的含义非常直接：第 t 块预算只有在 prompt 经历前 $t-1$ 轮后仍未退出时才会被实际消耗，因此各块大小应与“仍然值得继续投入的概率”共同决定总成本。

3.5.1　平衡退出规则的停止时间

在平衡退出规则下，prompt 之所以会继续留在活跃集合中，仅仅因为当前已观察到的回答仍然全对或全错。于是，在累计预算为 M_t 时，其存活概率满足

$$q_t^{\mathrm{bal}}(x) = p_x^{M_t} + (1 - p_x)^{M_t}. \tag{3.14}$$

因此，平衡规则下的期望成本可写为

$$\mathbb{E}[C_{\mathrm{bal}} \mid x] = \sum_{t=1}^{T} B_t \Big(p_x^{M_{t-1}} + (1 - p_x)^{M_{t-1}} \Big). \tag{3.15}$$

该式揭示出一个关键性质：当 p_x 接近 0 或 1 时，$q_t^{\mathrm{bal}}(x)$ 会衰减得非常慢，因为 prompt 很容易持续停留在“全错”或“全对”的单侧状态。于是，平衡规则会把大量后续预算投入到那些最不容易形成双侧对照的样本上，这正是其在训练中后期预算效率下降的根源。

3.5.2 正样本优先规则的停止时间

在正样本优先规则下，prompt 继续存活只意味着截至当前仍未观察到任何一个正确回答。于是有

$$q_t^{\text{pos}}(x) = (1 - p_x)^{M_t}, \tag{3.16}$$

从而

$$\mathbb{E}[C_{\text{pos}} \mid x] = \sum_{t=1}^{T} B_t (1 - p_x)^{M_{t-1}}. \tag{3.17}$$

与平衡规则相比，正样本优先规则完全移除了 $p_x \to 1$ 这一端的“找错成本”。当 prompt 已经较容易答对时，它在前几轮就会快速退出；真正继续消耗预算的，主要是那些 p_x 较低、仍有必要继续探索的样本。因此，这一规则天然对应一种更强的预算右移机制：越难获得正样本的 prompt，越能保留后续预算；越容易获得正样本的 prompt，越早退出。

3.5.3 单位预算的边际信号收益

进一步地，可将第 t 轮预算带来的“新增可辨别概率”写为

$$\Delta_t(x) = q_{t-1}(x) - q_t(x), \tag{3.18}$$

并定义第 t 块的单位预算边际收益为

$$g_t(x) = \frac{\Delta_t(x)}{B_t}. \tag{3.19}$$

如果 $g_t(x)$ 很低，说明继续为该 prompt 投入这一块预算，能够显著改变训练信号状态的概率并不高。对于平衡规则，这种情况会同时出现在极难样本和极易样本两端；而对正样本优先规则，它主要集中在极难样本一侧。也就是说，后者把“无效追加预算”的区域从两端压缩为一端，因此在平均成本相近时往往具有更好的总体效率。

这一分析也解释了为什么本文采用几何块而不是等长小块：当后续块大小逐轮增大时，系统实际上是在把更大的预算块留给那些在前几轮仍然保持较高 $q_t(x)$ 的样本。换言之，几何块策略并不是随意的工程折衷，而是把“先用廉价小块快速排除明显样本，再对难分样本集中加码”的预算哲学直接编码进采样流程。

3.6　训练时采样流程的算法化描述

为了将上述框架落到可执行流程，算法 1 给出了训练阶段的 prompt 级自适应采样过程。它强调两个关键状态：其一是活跃 prompt 集合，即当前仍需继续采样的题目；其二是每个 prompt 已累计的样本池，用于判断是否满足退出条件。相比“一次性采完再过滤”的被动流程，该算法在每一轮之后都会收缩活跃集合，因此能够将后续预算逐渐集中到最难分辨的样本上。

算法 1 几何块自适应采样流程

Require: Prompt 批次 $\mathcal{X}$，块序列 $\mathcal{B} = \{2, 2, 4, 8, 16\}$，退出规则 $\mathcal{R}$

Ensure: 每个 prompt 的样本池 S_x 及最终是否缺失有效信号的标记

```
初始化活跃集合 A ← X
for all x ∈ X do
    S_x ← ∅
end for
for b ∈ B do
    for all x ∈ A do
        从 π_θ(· | x) 采样 b 个回答并加入 S_x
    end for
    A_next ← ∅
    for all x ∈ A do
        if R(S_x) = continue then
            将 x 加入 A_next
        end if
    end for
    A ← A_next
    if A = ∅ then
        break
    end if
end for
for all x ∈ X do
    根据 S_x 判断是否形成有效信号，并执行后续下采样与更新构造
end for
```

3.7 复杂度与系统实现讨论

若设初始 prompt 数量为 N，第 t 轮仍然活跃的 prompt 数量为 N_t，对应块大小为 B_t，则总采样成本可以写为

$$C_{\text{total}} = \sum_t N_t B_t. \tag{3.20}$$

固定组大小策略的成本则为 $C_{\text{fixed}} = N \cdot n$。两者的差异不在于是否都需要为每个 prompt 生成回答，而在于自适应采样允许 N_t 随轮次快速下降。只要简单题与极难题能在前几轮被识别出来，就有机会在后续大块预算到来前从活跃集合中退出，从而压低总体成本。

从显存与缓存角度看，几何块策略还带来另一层收益。对于保留在活跃集合中的 prompt，其前缀往往已经被多轮复用，因此后续继续生成更长回答或更多回答时，能够更自然地复用已有的 KV Cache 状态。换言之，块结构越规整，越容易在系统层面实现“先筛查、后集中扩展”的执行模式；这正是本文强调几何块策略不仅有统计意义，也有工程意义的原因。

3.8 分布一致性扩展讨论

当采样块大小不断变化时，固定温度采样可能带来隐式的分布偏移问题。理论上，可令温度随块大小按对数规律调整：

$$T_t = T_0\big(1 + \alpha \log_2 B_t\big), \tag{3.21}$$

其中 B_t 为第 t 轮块大小，α 为缩放系数。若跨轮次温度不同，则可进一步采用重要性权重

$$\rho(y \mid x) = \frac{\pi_\theta(y \mid x; T_{\text{target}})}{\pi_\theta(y \mid x; T_{\text{sample}})} \tag{3.22}$$

对梯度估计进行校正 [36–39]。

考虑到当前已获得的实验数据主要集中于 prompt 级正确率分布、训练动态与退出规则对比，本文在实验部分重点验证难度感知退出与几何块预算的统计有效性；温度缩放与重要性采样则作为后续完整系统实现的理论扩展方向保留，其直觉也与动态温度采样研究中的“在不同时刻维持合适探索强度”相一致 [36–39, 43]。

3.9　本章小结

本章从概率建模、预算效率和系统组织三个角度给出了难度感知自适应采样的形式化描述。核心思想并不复杂：在训练过程中，不同 prompt 对额外采样预算的边际收益并不相同，因此采样次数不应是固定常数，而应由样本难度与退出规则共同决定。围绕这一思想，本文进一步提出了几何块调度、活跃集合迭代与后续更新构造的统一流程，为下一章的实验比较提供了清晰的实现对象与分析基线。

第 4 章　实验设计与结果分析

4.1　实验设置

本文使用的主要数据来自两个来源。第一部分数据是 OpenR1-Math-220k 上的 10,000 条 prompt 抽样结果，来自 Qwen2.5-Math-1.5B base 模型；其中每道题均进行了 256 次重复采样，用于估计 prompt 级正确率分布。第二部分数据为同一模型在训练步数 $0, 100, \ldots, 600$ 的 checkpoint 切片，用于观察训练过程中的分布迁移与信号坍塌变化。

除非特别说明，本文采用如下统计口径：若某题在 256 次采样中答对 k 次，则其经验正确率记为 $\hat{p}_x = k/256$。随后用 $\hat{p}_x$ 估计固定组大小下的全对/全错概率，并据此计算不同采样策略的 signal collapse 风险。

4.2　Prompt 难度分布统计

表 4.1 汇总了 10,000 条样本的总体难度分布。可以看到，该数据切片并不是围绕单一中间难度聚集，而是同时包含大量低成功率 prompt 与较长的高成功率尾部。这一结构意味着：若使用固定小组采样，训练中既会频繁遇到“全错组”，也会在后期逐步出现“全对组”。

表 4.1 OpenR1-Math-220k 抽样数据的 prompt 正确率统计摘要

Table 4.1 Summary statistics of prompt accuracy on the sampled OpenR1-Math-220k slice.

统计量	数值
平均正确率	0.2623
中位数正确率	0.1055
标准差	0.3133
非零正确率样本占比	81.54%
正确率恰为 0 的样本占比	18.46%
正确率恰为 1 的样本占比	0.56%
P_{25}	0.0078
P_{75}	0.4609
P_{90}	0.8164

进一步按桶统计后，正确率位于 0 ～ 8/256 的样本占比达到 37.01%，而 129/256 以上的中高正确率样本占比为 23.15%。这表明训练语料内部存在显著难度分层，固定预算不可能同时兼顾所有 prompt 的最优采样需求。

图 4.1 给出了原始 10,000 条样本的双视角分布图。左图展示精确到 256 桶的正确次数直方分布，右图展示归一化后的正确率直方图。可以看到，分布在 0/256 附近存在极高尖峰，而中高正确率区域则呈现较长尾部。这种“左端堆积 + 右端长尾”的结构意味着，如果对所有 prompt 一律采用固定小组采样，那么早期训练会频繁遇到全错组，而后期随着简单题增多，又会逐步积累全对组。

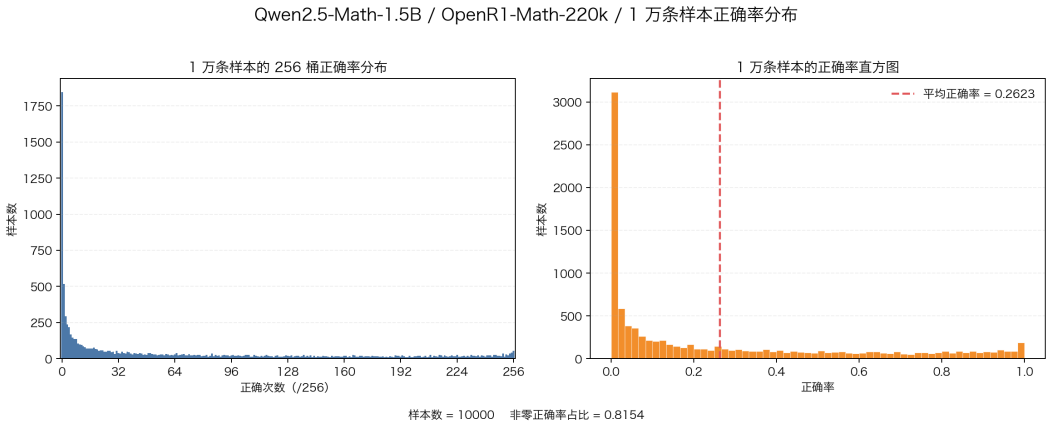

图 4.1 原始样本的 prompt 正确率分布图

Figure 4.1 Prompt-level accuracy distribution of the sampled OpenR1-Math-220k slice.

如果从累计分布角度继续观察，可以更清楚地看到“中位数很低但上尾较长”这一事实。图 4.2 显示，约一半样本的经验正确率仍停留在较低区间，但右侧累计曲线在中高正确率区域下降得并不陡峭，说明高通过率 prompt 仍然占据不可忽视的质量。也就是说，这一训练切片并非单纯“整体都很难”，而是同时容纳了多个难度层级；固定组大小因而必须在“为难题多采一些”和“避免为易题浪费太多”之间做出不可能两全的折衷。

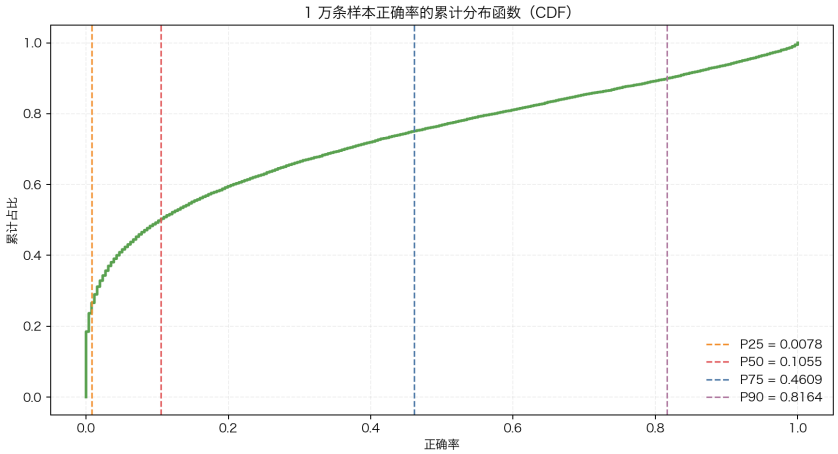

图 4.2 原始样本 prompt 正确率的累计分布

Figure 4.2 Cumulative distribution of prompt-level accuracy on the sampled slice.

4.3　信号坍塌的训练前后对比

基于 prompt 级经验正确率，本文分别估计训练初始点与训练第 600 步时不同组大小下的总体坍塌率。结果如表 4.2 所示。可以看到，增大组大小确实会降低全对/全错造成的零信号比例，但即使在 $n = 32$ 时，训练初始点仍有 35.36% 的 prompt 处于坍塌状态；到训练第 600 步，虽然整体正确率上升，坍塌率依然有 26.41%。

表 4.2 训练前后不同组大小下的 signal collapse 概率

Table 4.2 Estimated signal collapse probability under different group sizes before and after training.

训练阶段	$n = 4$	$n = 8$	$n = 16$	$n = 32$
Step 0	65.35%	52.91%	43.08%	35.36%
Step 600	55.95%	41.98%	32.75%	26.41%

这一结果说明两点。首先，所谓零信号并非个别异常样本，而是固定小组采样在真实训练分布上的系统性现象。其次，随着训练推进，虽然“全错”比例下降，但“全对”比例会同步上升，因此坍塌并不会自动消失，而是会以新的形式持续存在。

这一点还可以从 pass@k 与坍塌率的对应关系中得到更直观的理解。图 4.3 表明，随着采样次数增大，pass@k 的确会持续上升，但 signal collapse 的下降速度并不与之同步。这意味着“多采几次更容易采到对答案”与“多采几次就一定能

形成可用于组相对更新的信号”并不是同一件事：前者只要求至少出现一次成功，后者则要求在预算内形成足够稳定的对比结构。因此，单纯增加 rollout 数并不能自动消除固定预算的结构性浪费。

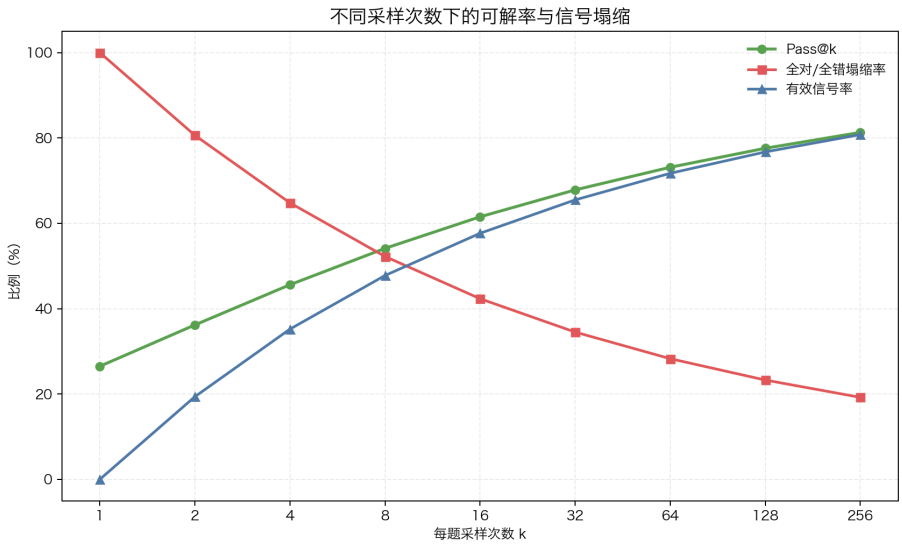

图 4.3 pass@k 增长与 signal collapse 下降并不同步

Figure 4.3 The growth of pass@k is not synchronized with the decline of signal collapse.

为了更清楚地说明这一点，表 4.3 进一步将总体坍塌率分解为“全错坍塌”与“全对坍塌”两部分。可以看到，在训练起点，零信号主要由全错主导；但到第 600 步后，随着模型整体能力提升，$n = 8, 16, 32$ 下的全对坍塌分别上升到 11.84%、7.58% 和 4.59%。这表明训练并不是简单消除了坍塌，而是将其来源从“做不出来”逐渐转向“过于容易而缺少负样本”。

表 4.3 训练前后 signal collapse 的全错/全对分解

Table 4.3 Decomposition of signal collapse into all-wrong and all-correct events.

训练阶段	指标	$n = 8$	$n = 16$	$n = 32$
Step 0	全错坍塌	46.48%	39.12%	32.90%
Step 0	全对坍塌	6.43%	3.95%	2.46%
Step 600	全错坍塌	30.14%	25.17%	21.82%
Step 600	全对坍塌	11.84%	7.58%	4.59%

4.4　自适应采样策略比较

本文进一步比较固定预算、固定块自适应与几何块自适应三类策略。比较时分别采用两种退出规则：其一为“有对有错就停”的平衡规则；其二为“只要有对就停”的正样本优先规则。表 4.4 与表 4.5 汇报了在训练全过程上的平均采样成本与信号缺失率。

表 4.4 规则 A：有对有错就停时的采样成本与信号缺失率

Table 4.4 Sampling cost and missing-signal rate under Rule A.

策略	预算序列	平均采样数	信号缺失率
固定 8 次采样	8	8.0000	46.02%
固定 16 次采样	16	16.0000	36.28%
固定块自适应	4+4+4+4+4+4+4+4	15.1211	29.36%
几何块自适应	2+2+4+8+16	15.4211	29.36%

表 4.5 规则 B：只要有对就停时的采样成本与信号缺失率

Table 4.5 Sampling cost and missing-signal rate under Rule B.

策略	预算序列	平均采样数	信号缺失率
固定 8 次采样	8	8.0000	37.16%
固定 16 次采样	16	16.0000	30.74%
固定块自适应	4+4+4+4+4+4+4+4	13.2102	26.02%
几何块自适应	2+2+4+8+16	12.8240	26.02%

从规则 A 可以看出，自适应采样相较于固定 16 次采样，在平均成本略低的同时将缺失率从 36.28% 压低到 29.36%。在规则 B 下，几何块自适应与固定块自适应具有完全一致的缺失率，但平均采样数进一步下降到 12.8240，说明几何块结构并未带来统计层面的明显负担。

若将这种差异写成相对改进幅度，则结论会更加直观。在规则 A 下，固定块自适应相对固定 16 次采样将平均成本降低了 5.49%，同时将信号缺失率再压低 6.92 个百分点；几何块自适应虽然成本降幅略小，为 3.62%，但在缺失率上达到完全相同的改善。在规则 B 下，几何块自适应的优势更明显：相对固定 16 次采样，它将平均采样数进一步降低了 19.85%，同时仍把缺失率从 30.74% 压低到

26.02%。这表明在“只要采到正样本即可停止”的预算逻辑下，几何块调度可以同时获得更低成本与更低缺失率。

综合来看，几何块方案的意义不在于对任意指标都绝对占优，而在于它以与固定块几乎相同的统计效果，换来了更加规整的批次组织形式。这种结构化收益为后续 KV Cache 复用与系统并行执行提供了更自然的接口。

如果把这些结果放回上一章的停止时间分析框架中理解，规律会更加清楚。规则 A 需要同时看到正负样本，因此在 p_x 接近 1 的右端区域，很多 prompt 会为“再找一个错误样本”持续存活；规则 B 则在看到首个正样本后即可退出，于是简单题会更早离开活跃集合。也正因为如此，规则 B 的平均采样数下降更明显，而缺失率并没有反弹，说明预算确实从“已经基本确定的简单题”转移到了“仍然可能产生信息增量的困难题”。

为了更具体地说明这种预算再分配，图 4.4 比较了原始抽样分布与训练过滤后的保留分布。可以看到，过滤后的保留池在极低正确率区域的权重下降，而中低到中等正确率区域的占比相对抬升。这一现象并不意味着训练应当简单删除所有难题，而是说明真正值得继续分配额外 rollout 的，往往是那些既不是稳定全错、也不是稳定全对的过渡区间样本。它们恰好对应本文所强调的“单位预算信息回报”更高的难度带。

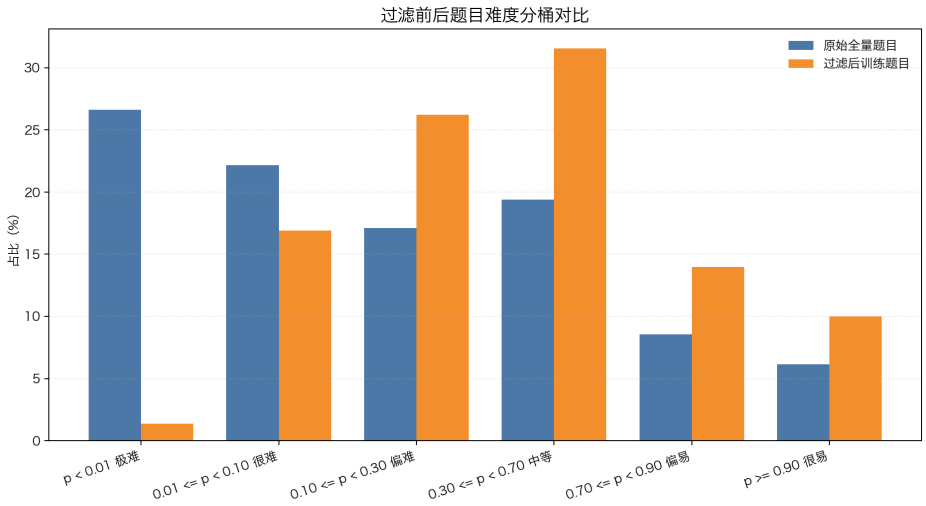

图 4.4 原始样本与训练过滤后保留池的难度分桶对比

Figure 4.4 Difficulty-bucket comparison between the original sample and the training-filtered retained pool.

4.5　训练动态分析

表 4.6 汇总了训练关键阶段的奖励与分位数变化。训练从 step 0 到 step 600，平均奖励由 0.2623 提升至 0.4025，中位数正确率由 0.1055 提升至 0.3750，上四分位由 0.4609 提升至 0.7266，说明整体能力分布持续右移。

表 4.6 训练过程中的奖励与分布迁移摘要

Table 4.6 Summary of reward and distribution shift during training.

Step	平均奖励	0/256 占比	中位数 P_{50}	上四分位 P_{75}
0	0.2623	18.46%	0.1055	0.4609
300	0.3325	11.50%	0.2539	0.6211
600	0.4025	10.69%	0.3750	0.7266

若进一步观察全过程，可以发现训练改进并不是均匀发生在所有难度区间。表 4.7 给出了每 100 步的奖励、极难样本占比以及中高正确率区间的迁移情况。训练 600 步后，平均奖励相对初始点提升了 53.44%；0/256 占比从 18.46% 下降到 10.69%；而 150–220/256 区间占比则从 11.55% 上升到 19.47%，说明大批样本从“偶尔做对”向“较高稳定度做对”迁移。

表 4.7 训练全过程的阶段性分布迁移

Table 4.7 Stage-wise distribution shift during training.

Step	Reward	0/256	≤ 8/256	P_{50}	150–220/256	220+/256
0	0.2623	18.46%	37.01%	0.1055	11.55%	8.20%
100	0.2786	18.45%	31.78%	0.1445	12.01%	9.21%
200	0.3031	12.57%	26.94%	0.1992	13.07%	10.64%
300	0.3325	11.50%	26.59%	0.2539	14.77%	12.38%
400	0.3606	11.50%	26.59%	0.3047	15.35%	12.82%
500	0.3833	11.37%	26.59%	0.3438	16.94%	13.01%
600	0.4025	10.69%	26.58%	0.3750	19.47%	13.76%

这个全过程表格揭示出两个更细的现象。第一，训练前 200 步的主要变化来自左尾收缩，即极难样本大量减少；但 300 步之后，≤ 8/256 的总体占比几乎不再下降，说明最难部分很快进入平台区。第二，后续收益主要表现为中位数与中高正确率区间的持续抬升，即模型在“做得偶尔对”和“做得比较稳”之间发生结构

性右移，而不是简单把所有样本都推到极高正确率。这意味着后期训练更需要精细地维持难度梯度，否则简单题上的全对组会越来越多，进一步稀释有效训练信号。

如果进一步与总体奖励提升结合来看，可以发现训练收益与坍塌来源迁移是同步发生的：从 step 0 到 step 600，平均奖励累计提升 53.45%，说明模型确实在持续学习；但与此同时，step 600 时全对坍塌已分别占到 $n = 8, 16, 32$ 总坍塌量的 28.20%、23.15% 和 17.38%。这意味着后期训练中的零信号并不主要来自“模型什么都做不对”，而越来越来自“简单题已经做得过于稳定”。也正因为如此，后期若仍采用固定预算，额外采样就会越来越多地浪费在已无辨别力的简单 prompt 上。

为了把这一过程可视化，图 4.5 和图 4.6 分别给出了训练奖励曲线以及不同 checkpoint 的平滑分布总览。奖励曲线显示训练过程基本单调提升，没有出现明显震荡回退；而 checkpoint 总览图则更清楚地展示了分布形态如何从“极端偏左”逐渐过渡到“中间抬升、右侧增强”。尤其是在 step 300 之后，分布曲线在中高正确率区间逐步抬升，但最左端尖峰并未完全消失，这与表格中“左尾平台化、右侧持续抬升”的判断一致。

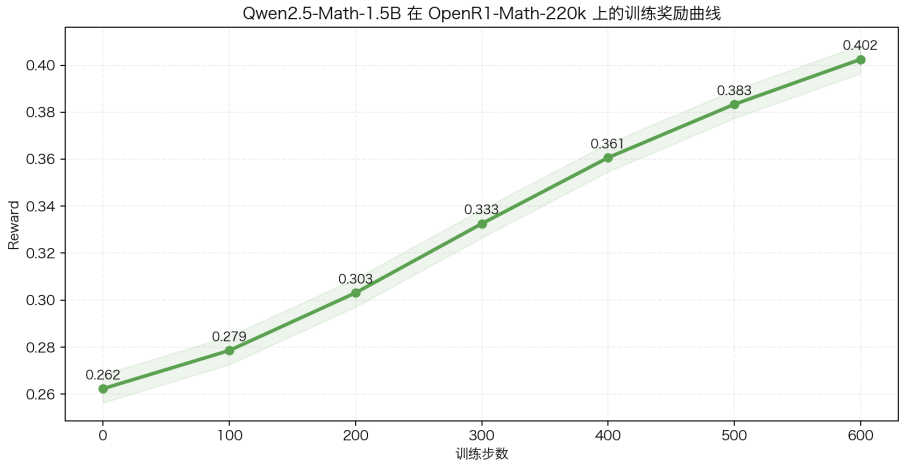

图 4.5 训练过程中的平均奖励曲线

Figure 4.5 Average reward curve during training.

值得注意的是，训练后期虽然极低正确率样本比例明显下降，但低端尾部并未完全消失，0/256 的样本占比仍超过 10%。与此同时，较高正确率区域不断扩张，导致“全对”样本的风险随之上升。换言之，训练动态并不会自然消除 signal

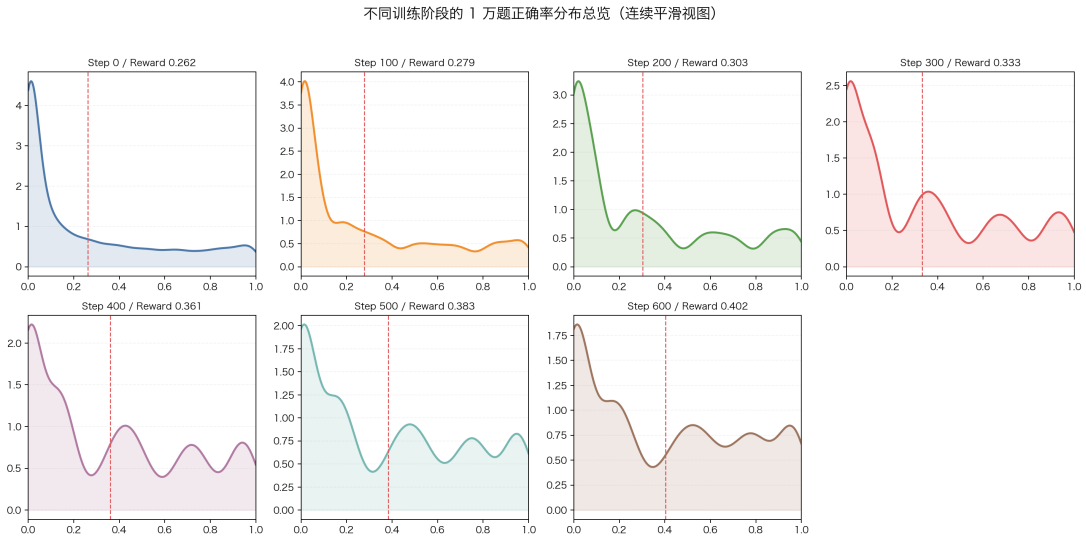

图 4.6 不同 checkpoint 的正确率分布平滑总览

Figure 4.6 Smoothed overview of prompt-accuracy distributions across checkpoints.

collapse，而是将其从“难题全错”逐渐转化为“易题全对”。这正是本文主张采用难度感知采样而非统一固定预算的根本原因。

若把本章所有证据合并起来，实际上可以得到一个更强的实验结论：本文提出的自适应采样并不是“为了少采一点而少采一点”，而是在训练过程中持续追踪哪里还存在可被观测的差异，并把预算集中投给这些区域。分布统计说明异质性真实存在，坍塌分解说明零信号会在训练前后迁移但不会消失，策略比较说明退出规则与块组织方式会改变预算效率，训练动态则说明这种预算再分配需求会随着模型能力提升而越来越强。四类证据共同支持了本文的中心论点，即采样预算本身构成了训练信号设计的一部分。

4.6　本章小结

本章围绕引言中提出的三个核心问题给出了对应证据。首先，prompt 级正确率分布同时呈现左端堆积和右侧长尾，说明训练数据内部存在显著难度异质性，固定预算难以为不同 prompt 提供同样合适的采样强度。其次，signal collapse 在训练前后都保持较高占比，只是其来源随着训练推进从“全错主导”逐渐转向“全对增加”，因此零信号并不会因为模型能力提升而自动消失。

进一步的策略比较表明，自适应采样能够在相近甚至更低成本下显著降低信号缺失率；其中，几何块组织与固定块策略在统计效果上基本相当，但批次形

态更加规整，而正样本优先退出规则在当前预算设定下表现出更高的成本收益比。换言之，实验结果不仅验证了难度感知预算分配的必要性，也支持了本文在方法章节中提出的“统计效率—系统效率联合设计”观点。

基于这些结果，下一章将进一步讨论两个问题：其一，为什么正样本优先规则会在训练中后期表现出更好的预算效率；其二，为什么几何块结构的价值不应只用单次统计指标衡量，而应放到真实训练系统的批次调度与 KV Cache 复用场景中理解。

第 5 章　讨论

5.1　为何正样本优先规则更具预算效率

根据本文统计结果，正样本优先规则在与平衡规则相同的缺失率水平下获得了更低的平均采样成本。这一现象的本质在于：随着模型能力增强，简单 prompt 更容易在前几轮便产生正确答案，而继续追求“必须同时看到错误样本”的目标，将把大量预算消耗在少数 hard negative 的搜索上。对训练系统而言，这部分预算未必比转移给中等难度 prompt 更具边际收益。

因此，正样本优先规则并不是否定负样本的重要性，而是在预算有限的训练现实中重新排序不同 prompt 的优先级。它体现的是一种预算再分配思想：对简单题适度早停，对难题保留更大的探索空间。

若将这一解释与第三章中的等待时间分析对应起来，就可以更清楚地理解第四章实验结果。对平衡规则而言，有效信号出现概率由 $q_{\mathrm{bal}}(p_x; n) = 1-p_x^n-(1-p_x)^n$ 决定；当 p_x 逐渐接近 1 时，等待一个错误样本的代价会迅速上升。第四章表 4.4 与表 4.5 的差异，正是这一机制的经验体现：在相同或更低的信号缺失率下，正样本优先规则显著降低了平均采样数，说明后期训练中的主要瓶颈已经不再是“找不到正确答案”，而是“为了维持平衡而额外寻找错误答案”。

同样地，训练动态分析也为这一判断提供了额外支撑。表 4.7 显示，随着训练推进，极难样本占比下降而中高正确率区间持续扩张，这意味着越来越多 prompt 进入“正样本易得、负样本稀缺”的区域。于是，正样本优先规则的优势并不是某个孤立超参数设置下的偶然结果，而是由训练分布右移所诱发的阶段性结构变化。换言之，退出规则的最优性并非静态常数，而与模型当前能力水平和 prompt 难度分布共同决定。

从停止时间视角看，平衡规则同时受到“右端找错难”和“左端找对难”两类成本的拖累；而正样本优先规则主动放弃了前者，因此把高成本区域压缩到了低成功率一侧。只要训练中后期已经出现可观比例的高正确率 prompt，这种规则差异就会立刻转化为平均采样成本差异。换句话说，正样本优先的优势并不依赖某一个特定数据集，而是来源于其对后训练分布右移趋势的结构性适配。

5.2 几何块策略的联合收益

从纯统计角度看，几何块自适应与固定块自适应在多数设置下非常接近；但从训练系统角度看，几何块策略具有更规整的批次形态。前两轮采用小块快速筛查，后续大块则可更好地匹配现代推理引擎对同前缀多回答生成的优化需求[40–42]。这意味着几何块方法有望将“统计效率接近不变”的优势转化为“系统吞吐进一步提升”的优势。

更具体地说，几何块策略的价值并不只是“把 32 次采样拆成若干轮”，而是把 prompt 的生命周期分成了两个截然不同的阶段：早期筛查阶段用极小块快速识别简单题和极难题，中后期扩展阶段则只对仍然模糊的 prompt 投放大块预算。这种结构一方面降低了无效采样占比，另一方面使活跃 prompt 集合在时间上逐渐收缩，从而为系统调度带来更高的可预测性。与随机长度或完全自由追加的采样方式相比，几何块方法更容易被实现为批量推理服务中的固定调度模板。

这一点也可以与第四章中的结果形成直接对应。尽管表 4.4 与表 4.5 中，几何块与固定块的信号缺失率几乎一致，但几何块在规则 B 下仍将平均采样数进一步降低到了 12.8240。换言之，它并没有通过牺牲统计质量来换取系统友好性，而是在统计效果近似不变的前提下，为批次组织提供了更规整的执行接口。因此，几何块策略的价值应被理解为“把统计上的自适应性转译成工程上的可调度性”，这也是本文强调其联合收益而非单点收益的原因。

这一点对于真实训练系统尤为关键。许多统计上“略优”的采样器在部署时并不一定高效，因为它们可能引入过于碎片化的调度、频繁的前缀失配或不可预测的批次形态。相比之下，几何块策略虽然不是最自由的在线策略，却在灵活性与可执行性之间取得了更稳健的平衡：前几轮用统一小块做宽筛，后几轮再用较大块做集中扩展，既保留了自适应能力，又保留了系统实现所需的规则性。

5.3 从采样策略到隐式课程学习

本文的另一个启示在于，自适应采样实际上会诱导一种隐式课程学习。传统课程学习通常显式定义“先学简单样本还是先学困难样本”的顺序，而本文所讨论的预算分配并不直接改变样本进入训练集的先后，而是改变不同样本在单位时间内能够获得多少 rollout 预算。其结果是：稳定全错和稳定全对的样本都会更快退出活跃集合，中等难度、结果最不确定的 prompt 会在训练过程中获得更高

的持续关注度。

这种机制与显式难度排序不同。它不是在数据层面对样本做一次性划分，而是在训练过程中根据当前策略的表现反复更新样本的“活跃程度”。于是，课程不再是预先写死的，而是由模型当前能力状态和退出规则共同生成的。对 reasoning 训练来说，这种动态课程往往比静态课程更合理，因为同一道题在训练早期和后期对应的有效信息密度并不相同。

5.4　与既有研究结论的关系

本文的观察与两类既有结论形成互补。其一，RL 主要激发已有能力而非创造新能力上限的观点，强调了潜在能力暴露的重要性 [20]。本文则进一步指出，若采样预算设计不当，模型即使已经具备潜在正确解，也可能因为固定小样本而无法在训练时显式暴露出来。其二，自一致性与 pass@k 研究强调多次采样的价值 [18, 19]；本文则补充说明，关键并不只是“采得更多”，而是“把额外预算投给最需要它的 prompt”。

从这个意义上看，本文也为“后训练主要在重排已有能力”这一判断提供了更细化的机制解释：当模型已有能力以高方差形式隐含存在时，采样预算的作用并不是创造新能力，而是让训练过程更高概率地观测到那些原本会被固定小样本掩盖的正负差异。因此，预算分配可以被理解为一种能力显化机制，而不仅仅是推理成本控制机制。

进一步地，这一解释也有助于理解为什么本文特别强调 prompt 级难度异质性。若所有样本都处在近似相同的成功率区间，那么固定预算虽然未必最优，但其代价也不会太高；真正导致预算浪费急剧放大的，是同一训练切片中同时存在极难、过渡和极易三类 prompt。当这种异质性与固定小组采样相遇时，训练系统就会在两端都付出高昂的“无差异观察成本”，而自适应预算恰恰是在削减这部分成本。

5.5　局限性

本文仍存在三方面局限。第一，当前定量分析主要基于 Qwen2.5-Math-1.5B base 在 OpenR1-Math-220k 上的单模型切片数据，尚未扩展到更大模型和多基准端到端训练。第二，关于温度缩放与重要性采样的讨论目前主要停留在理论层

面，尚缺少配套的完整系统实验。第三，本文从统计视角推断了几何块策略对 KV Cache 友好的潜在收益，但尚未直接报告 wall-clock 时间与吞吐测量结果。

这些局限并不削弱本文的核心结论：在 reasoning 强化学习后训练中，采样预算本身就是训练信号设计的一部分。后续工作可在更多模型、更多推理引擎和真实在线训练配置上进一步验证这一结论。

除此之外，本文还存在一个较为实际的限制：当前分析主要依据 prompt 终局正确率构造统计指标，而没有直接纳入答案长度、推理轨迹多样性以及步骤级 verifier 的反馈。如果未来训练系统更强调过程监督而非终局监督，那么“什么样的 rollout 才算形成有效信号”这一标准可能需要重新定义，相应的退出规则与预算分配器也应做相应调整。

5.6 效度威胁分析

除了一般性的局限外，本文还需要从研究效度角度对结论边界进行说明。

在内部效度方面，本文所使用的 prompt 级正确率均由有限次重复采样估计而来，尽管 256 次已能提供较稳定的经验分布，但它终究只是对真实 p_x 的近似。当某些样本位于极低或极高成功率区域时，有限样本误差仍可能影响全对/全错概率的估计精度。此外，本文对预算效率的讨论以二值奖励和 prompt 级终局正确率为主，没有直接建模步骤级奖励或长度惩罚，因此结论主要适用于可验证终局奖励场景。

在外部效度方面，当前数据来自单一模型与单一训练切片。虽然 OpenR1-Math-220k 具有一定代表性，但其难度构成、题目风格和采样温度设置仍可能与其他数学基准、代码推理任务或多模态 reasoning 数据存在差异。因此，本文更适合被理解为“在当前 reasoning 训练形态下发现的稳定统计规律”，而不是对所有后训练任务的无条件结论。

在构念效度方面，本文将“有效训练信号”主要定义为 prompt 内部是否同时存在可形成对比的正负样本。这一定义对于组相对归一化更新是自然的，但对于完全不同的目标函数或值函数估计方法，signal collapse 的具体表现形式可能有所变化。换言之，本文分析的是一类与组采样直接相关的训练障碍，而不是所有强化学习训练障碍的统一解释。

尽管存在这些威胁，本文的主要结论仍具有稳健性：固定小组采样在难度异

质数据上会系统性地产生零信号区域，而自适应预算分配能够以更高概率恢复这些区域中的可学习差异。未来工作可以通过更大规模端到端训练、更多模型家族以及更细粒度奖励设计，对这一结论进行进一步外推与修正。

5.7　实践启示与设计建议

基于全文分析，本文给出以下几条面向实际训练系统的设计建议。

第一，对于早期试验阶段，不宜一开始就盲目增大组大小。固定大组虽然能够降低坍塌率，但其代价是线性上升的推理成本。更合理的做法是先采用小块自适应采样观察 prompt 分布，再根据分布形态决定是否值得扩大预算上限。换言之，组大小不应被视为静态超参数，而应被视为与数据难度共同决定的动态配置。

第二，在模型已经具备一定基础能力的中后期训练中，建议优先采用正样本优先退出规则。本文的统计表明，此时零信号的一大来源已经从“全错”转向“全对”，继续在简单题上强求 hard negative 的边际收益会显著下降。更优策略是让简单题较早退出，把更多预算保留给中等难度样本，以维持有效的正负对照区间。

第三，自适应采样的部署应尽量与推理引擎的前缀复用机制结合。若系统能够在同一 prompt 的多轮采样之间保留 KV Cache，则几何块策略的工程收益将比本文静态统计所体现的收益更大。这意味着未来的训练框架设计不应将“统计采样器”和“推理执行器”分离实现，而应尽量构造统一的数据流与缓存策略。

第四，训练监控指标也需要相应升级。除平均奖励、loss 和 pass@k 外，prompt 级全错率、全对率、活跃 prompt 比例以及不同难度区间的预算占比，都应作为常规诊断指标纳入日志系统。原因在于，只有直接观察这些统计量，才能判断训练是否陷入了“看似稳定、实则缺少对比信号”的隐性停滞状态。

总的来说，本文更倾向于将自适应采样理解为一种训练操作系统：它不仅决定样本如何被看见，也决定预算如何被消耗，以及哪些 prompt 会在训练过程中持续保有影响力。若这一层设计得当，后续关于奖励函数、长度控制和探索温度的许多优化才更可能真正生效。

第 6 章　结论与展望

本文围绕大语言模型数学推理后训练中的 signal collapse 问题，系统讨论了固定小组采样为何会在训练前后持续造成零梯度现象，以及难度感知自适应采样为何能够在有限预算下更有效地恢复训练信号。全文以 OpenR1-Math-220k 抽样数据与训练过程 checkpoint 切片为基础，从概率分析、预算效率、采样组织和系统实现四个层面展开研究，最终得到如下结论。贯穿全文的核心观点是：在可验证奖励的 reasoning 后训练中，采样预算不是优化器之外的外围参数，而是决定训练信号能否被看见的内部结构。

6.1　主要结论

第一，prompt 级正确率分布具有显著的长尾与分层特征，训练语料并不存在单一“平均难度”，而是同时包含大量接近全错的极难样本和一批高通过率样本。这意味着固定预算不可能同时满足不同难度样本的最优采样需求，也解释了为何统一组大小在 reasoning 场景下天然存在效率损失。

第二，signal collapse 并不是训练早期的暂时现象，而是在训练过程中以后验不同形式持续存在。训练前期，零信号主要来自困难样本形成的全错组；随着模型能力提升，后期零信号则越来越多地由简单样本形成的全对组主导。换言之，固定小组采样所造成的训练停滞不是阶段性偶然，而是由难度异质性与组内相对归一化共同诱发的结构性问题。

第三，自适应采样相较于固定预算具有明显优势。实验表明，无论采用平衡退出规则还是正样本优先退出规则，增量采样都能够在相近甚至更低的平均成本下显著降低信号缺失率。这说明在 reasoning 强化学习中，“采多少”并不是外在超参数，而是影响训练信号是否能够被看见的核心机制。

第四，几何块自适应虽然在统计效果上与固定块自适应接近，但其批次结构更加规整，更有利于同前缀多回答生成时的前缀复用与系统调度。因而，几何块方案的价值不只体现在少量成本差异上，更体现在它为后续 KV Cache 复用和在线推理流水线提供了更自然的执行接口。

第五，在当前数据与预算设定下，正样本优先退出规则较平衡退出规则表现

出更好的预算效率。这表明在模型已有一定基础能力的中后期训练阶段，将简单题上节省下来的预算转移给中等难度样本，往往比继续在简单题上搜索 hard negative 更有价值。该发现进一步支持了“预算应按 prompt 难度再分配”的基本观点。

6.2 本文贡献回收

回到全文开头提出的研究目标，本文主要完成了三方面工作。其一，在统计分析层面，本文从 prompt 级概率分布角度重新刻画了 reasoning RL 中的零梯度现象，将其抽象为 signal collapse，并建立了与组大小、正确率分布直接相关的分析框架，从而把“为什么会学不到”解释为“预算如何错配到不同难度样本上”的问题。其二，在采样机制层面，本文围绕退出规则与采样块组织方式，系统比较了固定预算、自适应固定块和几何块策略，进一步说明难度感知预算分配在统计上确实更高效，而正样本优先规则在当前预算下具有更好的成本收益比。其三，在系统实现层面，本文并未将采样仅理解为训练前置步骤，而是将其与系统批次组织、前缀复用、KV Cache 友好性以及后续可扩展的温度缩放重要性校正联系起来，从而把问题扩展为“统计效率—系统效率”的联合设计问题。

因此，本文的核心价值不在于提出一个局部采样 trick，而在于给出了一种新的理解框架：在可验证奖励的 reasoning 强化学习后训练中，训练信号质量既由 reward 定义决定，也由 prompt 级预算如何分配、何时停止和如何组织执行所共同决定。只有把这些因素放在统一视角下考虑，后训练中的许多表面不稳定现象才能被更系统地解释。这也是本文希望回收的主线：所谓训练稳定性，并不只是梯度估计器的性质，还包括训练系统是否真正看见了足够多的可比较样本。

6.3 未来展望

未来工作可以沿三个方向继续展开。第一，在统计层面，可进一步在更多模型规模、更多基准数据集以及不同 reward 形态下验证本文结论，尤其需要考察步骤级奖励、长度惩罚和多模态 reasoning 场景下 signal collapse 的表现形式是否发生变化。第二，在方法层面，可将温度缩放、重要性采样修正和置信区间停止规则纳入统一框架，构造更强的难度感知预算分配器，使 prompt 级预算分配不仅依赖经验正确率，还能显式利用不确定性信息，并进一步与在线难度预测器或

rollout replay 机制结合。第三，在系统层面，应进一步将几何块采样与真实在线推理引擎结合，直接测量 wall-clock 时间、吞吐率、cache 命中率和前缀复用收益，从而验证统计收益是否能够稳定转化为工程收益。

总而言之，面向 reasoning 训练的强化学习后训练不应仅关注损失函数或优化器形式，还应将 prompt 级预算分配、退出规则与系统批次组织视为统一设计对象。本文希望说明，采样不是训练外部的辅助过程，而是训练内部的一部分信号机制；这一认识对于后续大规模 reasoning 模型的训练设计具有持续的研究价值。

附录 A　附录：补充公式与统计说明

A.1　固定组采样下的 signal collapse 概率

设单个 prompt 的单次答对概率为 p_x，组大小为 n。若组内全部采样均正确，则其概率为 p_x^n；若组内全部采样均错误，则概率为 $(1-p_x)^n$。因此，发生 signal collapse 的 prompt 级概率为

$$P_{\text{collapse}}(x;n) = p_x^n + (1-p_x)^n. \tag{A.1}$$

若对训练分布求期望，即可得到总体坍塌率

$$P_{\text{collapse}}(n) = \mathbb{E}_{x\sim d_0}[p_x^n + (1-p_x)^n]. \tag{A.2}$$

该表达式说明，只有当 prompt 级正确率大量集中在中间区间且组大小足够大时，坍塌率才会明显下降；一旦训练集中同时存在大量接近 0 或接近 1 的样本，固定小组采样就会持续暴露全错或全对问题。

A.2　单位预算信息效率近似

对二值奖励而言，单样本方差信息与 $p_x(1-p_x)$ 成正比。若进一步考虑训练后期获取负样本的期望成本，可得到单位预算信息效率近似

$$\eta(p_x) \propto p_x(1-p_x)^2. \tag{A.3}$$

当 $p_x = 0.9$ 时，$\eta(p_x) = 0.009$；当 $p_x = 0.3$ 时，$\eta(p_x) = 0.147$。这说明中等偏难样本在相同预算下更可能产出高价值训练信号，也为本文采用难度感知预算分配提供了直观解释。

参考文献

[1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need [J/OL]. arXiv preprint arXiv:1706.03762, 2017. DOI: 10.48550/arXiv.1706.03762.

[2] Brown T B, et al. Language models are few-shot learners [EB/OL]. 2020. DOI: 10.48550/arXiv.2005.14165.

[3] Touvron H, Lavril T, Izacard G, et al. Llama: Open and efficient foundation language models [J/OL]. arXiv preprint arXiv:2302.13971, 2023. DOI: 10.48550/arXiv.2302.13971.

[4] Bai J, Bai S, Chu Y, et al. Qwen technical report [J/OL]. arXiv preprint arXiv:2309.16609, 2023. DOI: 10.48550/arXiv.2309.16609.

[5] Zhao W X, Zhou K, Li J, et al. A survey of large language models [Z]. 2023.

[6] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback [EB/OL]. 2022. DOI: 10.48550/arXiv.2203.02155.

[7] Dai J, Pan X, Sun R, et al. Safe rlhf: Safe reinforcement learning from human feedback [J/OL]. arXiv preprint arXiv:2310.12773, 2023. DOI: 10.48550/arXiv.2310.12773.

[8] Lee H, Phatale S, Mansoor H, et al. Rlaif vs. rlhf: Scaling reinforcement learning from human feedback with ai feedback [EB/OL]. 2023. DOI: 10.48550/arXiv.2309.00267.

[9] Chaudhari S, Aggarwal P, Murahari V, et al. Rlhf deciphered: A critical analysis of reinforcement learning from human feedback for llms [J/OL]. arXiv preprint arXiv:2404.08555, 2024. DOI: 10.48550/arXiv.2404.08555.

[10] DeepSeek-AI, et al. Deepseek-r1: Incentivizing reasoning capability in llms via reinforcement learning [EB/OL]. 2025. DOI: 10.48550/arXiv.2501.12948.

[11] Cobbe K, Kosaraju V, Bavarian M, et al. Training verifiers to solve math word problems [J/OL]. arXiv preprint arXiv:2110.14168, 2021. DOI: 10.48550/arXiv.2110.14168.

[12] Hendrycks D, Burns C, Kadavath S, et al. Measuring mathematical problem solving with the math dataset [J/OL]. arXiv preprint arXiv:2103.03874, 2021. DOI: 10.48550/arXiv.2103.03874.

[13] Lightman H, Kosaraju V, Burda Y, et al. Let's verify step by step [J/OL]. arXiv preprint arXiv:2305.20050, 2023. DOI: 10.48550/arXiv.2305.20050.

[14] Lewkowycz A, Andreassen A, Dohan D, et al. Solving quantitative reasoning problems with language models [J/OL]. arXiv preprint arXiv:2206.14858, 2022. DOI: 10.48550/arXiv.2206.14858.

[15] Ying H, Zhang S, Li L, et al. Internlm-math: Open math large language models toward veri-

fiable reasoning [J/OL]. arXiv preprint arXiv:2402.06332, 2024. DOI: 10.48550/arXiv.2402.06332.

[16] Zhang Y, Zeng Z, Li D, et al. Realsafe-r1: Safety-aligned deepseek-r1 without compromising reasoning capability [J/OL]. arXiv preprint arXiv:2504.10081, 2025. DOI: 10.48550/arXiv.2504.10081.

[17] Xiong W, Ye C, Liao B, et al. Reinforce-ada: An adaptive sampling framework under non-linear rl objectives [EB/OL]. 2025. DOI: 10.48550/arXiv.2510.04996.

[18] Chen M, Tworek J, Jun H, et al. Evaluating large language models trained on code [J/OL]. arXiv preprint arXiv:2107.03374, 2021. DOI: 10.48550/arXiv.2107.03374.

[19] Wang X, Wei J, Schuurmans D, et al. Self-consistency improves chain of thought reasoning in language models [J/OL]. arXiv preprint arXiv:2203.11171, 2022. DOI: 10.48550/arXiv.2203.11171.

[20] Kim M, Shrestha A, Shrestha S, et al. Reinforcement learning vs. distillation: Understanding accuracy and capability in llm reasoning [J/OL]. arXiv preprint arXiv:2505.14216, 2025. DOI: 10.48550/arXiv.2505.14216.

[21] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model [EB/OL]. 2023. DOI: 10.48550/arXiv.2305.18290.

[22] Ahmadian A, Cremer C, Galle M, et al. Back to basics: Revisiting reinforce style optimization for learning from human feedback in llms [J/OL]. arXiv preprint arXiv:2402.14740, 2024. DOI: 10.48550/arXiv.2402.14740.

[23] Lambert N, Pyatkin V, Morrison J, et al. Rewardbench: Evaluating reward models for language modeling [J/OL]. arXiv preprint arXiv:2403.13787, 2024. DOI: 10.48550/arXiv.2403.13787.

[24] Shao Z, Wang P, Zhu Q, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models [J/OL]. arXiv preprint arXiv:2402.03300, 2024. DOI: 10.48550/arXiv.2402.03300.

[25] He C, Luo R, Bai Y, et al. Olympiadbench: A challenging benchmark for promoting agi with olympiad-level bilingual multimodal scientific problems [J/OL]. arXiv preprint arXiv:2402.14008, 2024. DOI: 10.48550/arXiv.2402.14008.

[26] Gao B, Song F, Yang Z, et al. Omni-math: A universal olympiad level mathematic benchmark for large language models [J/OL]. arXiv preprint arXiv:2410.07985, 2024. DOI: 10.48550/arXiv.2410.07985.

[27] Tsoukalas G, Lee J, Jennings J, et al. Putnambench: Evaluating neural theorem-provers on the putnam mathematical competition [J/OL]. arXiv preprint arXiv:2407.11214, 2024. DOI: 10.48550/arXiv.2407.11214.

[28] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large

language models [J/OL]. arXiv preprint arXiv:2201.11903, 2022. DOI: 10.48550/arXiv.2201.11903.

[29] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms [J/OL]. arXiv preprint arXiv:1707.06347, 2017. DOI: 10.48550/arXiv.1707.06347.

[30] Yue Y, Chen Z, Lu R, et al. Does reinforcement learning really incentivize reasoning capacity in llms beyond the base model? [J/OL]. arXiv preprint arXiv:2504.13837, 2025. DOI: 10.48550/arXiv.2504.13837.

[31] Yu Q, Zhang Z, Zhu R, et al. Dapo: An open-source llm reinforcement learning system at scale [J/OL]. arXiv preprint arXiv:2503.14476, 2025. DOI: 10.48550/arXiv.2503.14476.

[32] Zheng H, Zhou Y, Bartoldson B R, et al. Act only when it pays: Efficient reinforcement learning for llm reasoning via selective rollouts [J/OL]. arXiv preprint arXiv:2506.02177, 2025. DOI: 10.48550/arXiv.2506.02177.

[33] Kong D, Guo Q, Xi X, et al. Rethinking the sampling criteria in reinforcement learning for llm reasoning: A competence-difficulty alignment perspective [J/OL]. arXiv preprint arXiv:2505.17652, 2025. DOI: 10.48550/arXiv.2505.17652.

[34] Sun Y, Shen J, Wang Y, et al. Improving data efficiency for llm reinforcement fine-tuning through difficulty-targeted online data selection and rollout replay [J/OL]. arXiv preprint arXiv:2506.05316, 2025. DOI: 10.48550/arXiv.2506.05316.

[35] Qu Y, Wang Q, Mao Y, et al. Can prompt difficulty be online predicted for accelerating rl finetuning of reasoning models? [J/OL]. arXiv preprint arXiv:2507.04632, 2025. DOI: 10.48550/arXiv.2507.04632.

[36] Papini M, Manganini G, Metelli A M, et al. Policy gradient with active importance sampling [J/OL]. arXiv preprint arXiv:2405.05630, 2024. DOI: 10.48550/arXiv.2405.05630.

[37] Humayoo M, Zheng G, Dong X, et al. Relative importance sampling for off-policy actor-critic in deep reinforcement learning [J/OL]. arXiv preprint arXiv:1810.12558, 2018. DOI: 10.48550/arXiv.1810.12558.

[38] Rowland M, Harutyunyan A, van Hasselt H, et al. Conditional importance sampling for off-policy learning [J/OL]. arXiv preprint arXiv:1910.07479, 2019. DOI: 10.48550/arXiv.1910.07479.

[39] Huang J, Jiang N. From importance sampling to doubly robust policy gradient [EB/OL]. 2019. DOI: 10.48550/arXiv.1910.09066.

[40] Xu Y, Khaira N K, Singh T. Kv cache optimization strategies for scalable and efficient llm inference [EB/OL]. 2026. DOI: 10.48550/arXiv.2603.20397.

[41] Jaillet P, Jiang J, Mellou K, et al. Online scheduling for llm inference with kv cache constraints [J/OL]. arXiv preprint arXiv:2502.07115, 2025. DOI: 10.48550/arXiv.2502.07115.

[42] Dong Y, Miao Y, Li W, et al. Accelerating llm inference throughput via asynchronous kv cache prefetching [EB/OL]. 2025. DOI: 10.48550/arXiv.2504.06319.

[43] Zhang S, Bao Y, Huang S. Edt: Improving large language models' generation by entropy-based dynamic temperature sampling [EB/OL]. 2024. DOI: 10.48550/arXiv.2403.14541.

致谢

本论文的完成离不开许多老师、同学、家人和朋友的帮助与支持。在论文写作与研究开展过程中，我始终受益于他们在学术、工作与生活上的鼓励与陪伴，在此谨致以诚挚的谢意。

首先，我要衷心感谢我的导师李伟教授。导师在课题选择、研究设计、实验推进和论文撰写等各个阶段都给予了耐心而细致的指导。导师严谨求实的学术态度、对问题本质的敏锐把握以及对研究边界的审慎思考，使我在完成本论文的过程中受益匪浅。论文中关于大语言模型强化学习后训练、自适应采样效率以及信号坍塌机制的分析，均离不开导师在研究方法与学术表达上的长期指导。

感谢中国科学院计算技术研究所和中国科学院大学为我提供良好的学习与科研环境。研究所浓厚的学术氛围和开放的交流环境，使我能够在课程学习、文献阅读、实验复现与系统实现之间不断迭代，逐步形成对研究问题的完整认识。

感谢在课题研究过程中给予我帮助的各位老师和同学。无论是围绕强化学习后训练方法的讨论，还是关于实验设计、结果分析、图表组织与论文表达的交流，这些启发都帮助我不断修正研究思路、完善论文结构。感谢实验平台与开源社区提供的模型、数据与工具支持，使本论文中的分析与验证工作得以顺利开展。

最后，我要感谢家人一直以来的理解、包容与支持。在学习和科研压力较大的阶段，家人的鼓励始终是我坚持完成学业的重要力量。

谨以此文，向所有关心、帮助和支持过我的师长、同学、亲友致以衷心感谢。

作者简历及攻读学位期间发表的学术论文与研究成果

作者简历:

闫嘉序，男，中国科学院大学硕士研究生，专业为计算机科学与技术，培养单位为中国科学院计算技术研究所。攻读硕士学位期间，主要围绕大语言模型后训练、推理强化学习与采样效率优化等方向开展学习与研究工作。

已发表（或正式接受）的学术论文:

截至本论文定稿时，暂无与本学位论文直接对应的公开发表或正式录用学术论文。

申请或已获得的专利:

截至本论文定稿时，暂无与本学位论文直接相关的已申请或已授权专利。

参加的研究项目及获奖情况:

攻读学位期间，围绕大语言模型强化学习后训练中的自适应采样与预算效率问题开展了系统性的文献调研、实验分析与论文研究工作，相关阶段性成果已体现在本论文之中。获奖及项目情况以学校和研究所正式备案信息为准。